



FACULTATEA DE  
**AUTOMATICĂ ȘI  
CALCULATOARE**



Computer Science  
& Engineering  
Department

# Înțelegerea cancerului pulmonar cu ajutorul tehnicilor de ML

Diana-Cristina Nucuță

Coordonator științific:  
**ȘI. dr. ing. Mihai Nan**


Universitatea Națională de Știință și Tehnologie POLITEHNICA din București  
Facultatea de Automatică și Calculatoare  
Departamentul de Calculatoare

2 Iulie 2024

# Problemă. Context. Motivație.

*„Doctorii prescriu medicamente  
despre care știu foarte puțin ca să  
vindece boli despre care știu și mai  
puțin, ale unor ființe omenești despre  
care nu știu nimic.”*

François-Marie Arouet, M. de  
Voltaire



# Obiective

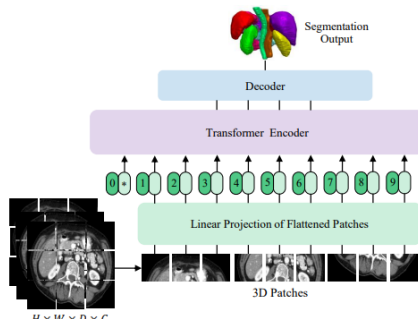
- generarea hărților de segmentare pentru tumorile mici
- propunerea unei strategii de antrenare a unui model de segmentare bazat pe UnetR pentru un set de date problematic
- explorarea hiperparametrilor în vederea determinării celei mai bune combinații

# Soluții existente

Echipa	DSC
K.A.V.athlon	0.61
NVDLMED	0.52
Lupin	0.55
CerebriuDIKU	0.59
LS Wang's Group	0.55


# Soluții existente (I)

- bazat pe învățare profundă
- identifică regiunile de interes în tomografii
- acuratețe de segmentare de 97.83%
- acuratețe de clasificare de 98.77%
- funcția de pierdere de entropie încrucișată



## Soluții existente (II)



- studiul cancerului la nivel de cohlee
- tomografii ale osului temporal
- vs modelul 3D U-Net, UNETR obține coeficienți Dice mai mari - batch\_size=1, DSC 0.92 pentru setul de testare al cohleei



# Prezentare set de date


- Decathlon Medical Dataset
- secțiuni  $512 \times 512$
- tumorile sunt codificate cu 1, iar fundalul cu 0
- împărțit pentru antrenarea și testare
- 63 tomografii pentru antrenare, 32 de tomografii pentru testare.
- 63 de tomografii - 51 pentru antrenarea propriu-zisă, 12 pentru validare.

# Prezentare set de date

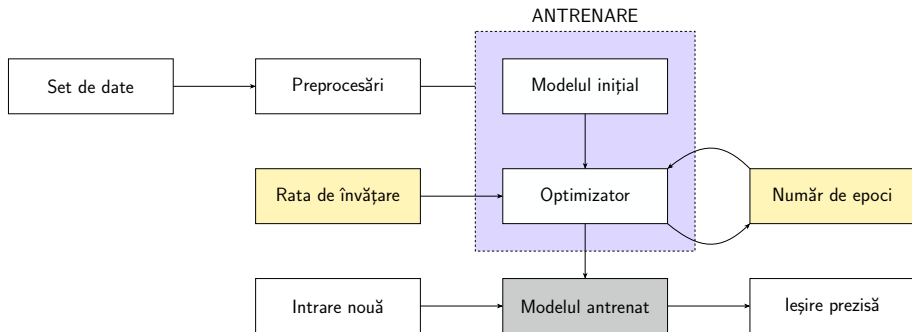




# Prezentare set de date



# Soluția propusă



# Rezultate experimentale

Echipa	DSC
K.A.V.athlon	0.61
NVDLMED	0.52
Lupin	0.55
CerebriuDIKU	0.59
LS Wang's Group	0.55
UNETR	0.58

# Rezultate experimentale

Optimizator	Număr de epoci	Rată de învățare	Cea mai bună metrică
Adam	200	0.01	0.4285
Adam	200	0.001	0.5035
AdamW	200	0.01	0.4918
AdamW	200	0.001	0.4909
Nadam	200	0.01	0.4987
Nadam	200	0.001	0.5030


# Rezultate experimentale(I)

Optimizator	Număr de epoci	Rată de învățare	Cea mai bună metrică
Adam	300	0.001	0.4764
AdamW	300	0.001	0.4991
Nadam	300	0.001	0.5505


## Rezultate experimentale(II)

Optimizator 1	Rata de învățare	Optimizator 2	Rata de învățare	Metrica 1	Metrica 2
Nadam	0.001	Adam	0.001	0.3793	0.5801
Adam	0.001	Adam	0.001	0.2611	0.5744
Adam	0.001	Nadam	0.001	0.2377	0.5709
AdamW	0.001	Nadam	0.0001	0.3380	0.5561

# Rezultate calitative




# Rezultate calitative (I)






## Rezultate calitative (II)



## Rezultate calitative (III)



# Concluzii

- generarea parțială a hărții de segmentare pentru zona de interes pentru tumorile mici
- eficiența și relevanța modelului UNETR în contextul specific al detectării și segmentării tumorilor pulmonare

# Dezvoltări ulterioare

- extinderea aplicării modelului UNETR în segmentarea tumorilor și pentru alte tipuri de cancer
- creșterea DSC pentru